

# Bio-Inspired Computing

## Wykład #2


dr Witold Bołt, 16.10.2024 r.



# Nobel z Chemi



AlphaFold, 2020





# Ogłoszenia

- Nie ma jeszcze grupy na Teams :( ale będzie
- Za tydzień 23 października 2024 r. - zajęcia **odwołane** (zarówno **wykład** jak i **laboratorium**)
  - Osoby, które w tym dniu zgodnie z planem powinny mieć laboratoria **wysyłają** swoje zadania **e-mail**. Zajęcia “*przepadają*”. Ocenię prace offline i napiszę każdemu feedback mailem.

# Wstępna rozpiska wykładów

| #  | Data       | Prowadzący        | Firma                             | Temat                  |
|----|------------|-------------------|-----------------------------------|------------------------|
| -  | 02.10.2024 | <b>ODWOŁANE</b>   |                                   |                        |
| 1  | 09.10.2024 | Witold Bołt       | Jit Team                          | Wprowadzenie           |
| 2  | 16.10.2024 | Witold Bołt       | Jit Team                          | Bio-Inspired Computing |
| -  | 23.10.2024 | <b>ODWOŁANE</b>   |                                   |                        |
| 3  | 30.10.2024 | Paweł Noga        | freelance                         | AI                     |
| 4  | 6.11.2024  | Krzysztof Kąkol   | Xebia                             | Jak działa ChatGPT     |
| 5  | 13.11.2024 | Marek Karpiński   | Gemini                            |                        |
| 6  | 20.11.2024 | Paweł Góra        | Center for Computational Medicine |                        |
| 7  | 27.11.2024 | wolny termin      |                                   |                        |
| 8  | 4.12.2024  | Michał Bojko      | Dynatrace                         |                        |
| 9  | 11.12.2024 | Filip Drzewiecki  | Jit Team                          |                        |
| 10 | 18.12.2024 | Marek Zmuda       | Intel                             |                        |
| 11 | 8.01.2025  | Stanisław Matczak | SmartRecrutiers                   |                        |
| 12 | 15.01.2025 | wolny termin      |                                   |                        |
| 13 | 22.01.2025 | Damian Kobiątka   | ColoredTree                       |                        |
| 14 | 29.01.2025 | Krzysztof Radecki | DAC.digital                       | Blockchain             |

# *Bio*-inspired Computing

*... kiedy **natura** pomaga informatyce*

Algorytmy Genetyczne

Automaty Komórkowe

# Algorytmy Genetyczne / Ewolucyjne



Przestrzeń wektorowe


$$\subseteq \mathbb{R}^n$$


$$\subseteq [0, 1]^n$$

$$\subseteq \{0, 1\}^n$$

search space

Przestrzeń w której poszukujemy *rozwiązania*.






**Przykład.** Wektory binarne długości  $n = 8$ . Czyli  $\mathbb{X} \subseteq \{0,1\}^8$ .



Fitness function

Funkcja dopasowania

$f:$   $X$



$R$

Dziedzina

Wektory...

Zbiór wartości

Zwykłe **liczby** :)

0 1 0 0 1 0 1 0



34.432984

1 0 1 0 1 1 1 0



-1.1430002

Kto ustala  $X$  oraz  $f$ ? Skąd je wziąć?


Sami wymyślamy! Jak? O tym później...

W szczególności może **nie** być ogólnego wzoru  
funkcja  $f$  a jedynie **procedura** liczenia wartości.

Problem **optymalizacji**. Szukamy takiego  $x \in \mathbb{X}$  dla którego  $f(x)$  jest **największe**.

*(... moglibyśmy policzyć pochodną, albo gradient...  
ale **nie wiadomo** czy się da!)*

Innymi słowy szukamy **maksimum** funkcji  $f$ ,  
... ale niestety nie zakładamy **nic** o tej funkcji  $f$



**Black box optimization.**




**Zadanie.** Jak optymalnie ustawić antenę?



wartość funkcji dopasowania  
siła odbieranego sygnału

konkretne ustawienie pokręteł  
wektor z przestrzeni  $\mathbb{X}$



panel sterowania anteny

# Pomysł! Zainspirujmy się przyrodą...

- Traktujemy elementy zbioru  $\mathbb{X}$  (wektory) jak **żywe organizmy**, a wartości funkcji  $f$  jako “współczynnik” **przystosowania** do otoczenia.
  - Żywe organizmy **rozmnażają się**.
  - Lepiej dostosowane osobniki mają większe szanse na **przeżycie** i wydanie **potomstwa**. Lepiej dostosowane osobniki są bardziej **atrakcyjne**.
  - W procesie rozmnażania następuje **dziedziczenie** cech - tzn. “potomek” ma część cech jednego “rodzica”, część cech drugiego “rodzica”.
  - Poza semi-deterministycznym procesem dziedziczenia cech, w życiu jest też szansa na **przypadek** - mutacje / zaburzenia, które wprowadzają **nowe** cechy nieistniejące u “rodziców”.
  - Żywe organizmy również się odżywiają, poruszają itd. Ale te aspekty życia **pomijamy**.



# Algorytmy Genetyczny / Ewolucyjny


- Będziemy pracować ze **skończonymi** podzbiorami  $\mathcal{P} \subset \mathbb{X}$ , które będziemy nazywać populacjami albo generacjami. Pierwsza - **inicjalna populacja** powstaje przez wylosowanie określonej liczby  $k > 0$  elementów z  $\mathbb{X}$ . (Póki co nie ma tu nic mądrego.) Inicjalną populację oznaczmy przez  $\mathcal{P}_0$ .
- Główny krok algorytmu to przepis na budowę populacji  $\mathcal{P}_i$  **na podstawie** populacji  $\mathcal{P}_{i-1}$ .
- Odpowiada to (*bardzo luźno*) procesowi następowania po sobie kolejnych pokoleń prostych organizmów żywych.



# Budowanie populacji


- Załóżmy, że  $\mathcal{P}_{i-1}$  jest nam znana. Będziemy budować  $\mathcal{P}_i$ .
- Liczymy wartości funkcji dopasowania dla osobników  $\mathcal{P}_{i-1}$  i zapisujemy.
- Powtarzamy  $k$  razy:
  - Losujemy dwa elementy z  $\mathcal{P}_{i-1}$ , niezależnie ze zwracaniem, w taki sposób, że prawdopodobieństwo wyboru danego elementu jest *proporcjonalne* do wartości jego funkcji dopasowania (*czym wyższa wartość tym wyższa szansa wyboru*). [operator **selekcji**]
  - Łączymy dwa wybrane elementy ucinając wektory w losowych miejscach i sklejać je. [operator **krzyżowania**]
  - Aplikujemy drobne zmiany na losowo wybranych pozycjach wyniku. [operator **mutacji**]
  - Tak utworzony element dodajemy do  $\mathcal{P}_i$ .
- **Opcjonalnie.** Zapewniamy, że ustalona liczba “najlepszych” względem wartości dopasowania elementów z  $\mathcal{P}_{i-1}$  przechodzi do  $\mathcal{P}_i$  **bez zmian**. [operacja zachowania elit - **elite survival**]

# Krzyżowanie jednorodne



ang. *uniform cross-over*




# Krzyżowanie jednopunktowe



ang. one point *cross-over*



# Mutacja



pozycje wybrane losowo

**Okazuje się, że to wystarczy!**

# Przykład: rozwiązywanie równań


[https://github.com/houp/ca-class/blob/main/simple\\_ga.ipynb](https://github.com/houp/ca-class/blob/main/simple_ga.ipynb)



# Co z tego wynika? Co tu widzimy?

- Bardzo prosta **sztuczna inteligencja!**
  - Program, który potrafi rozwiązywać szeroką klasę problemów, bez konieczności projektowania go “pod konkretny problem”.
- Możliwość stosowania w różnych dziedzinach. Również bardzo praktycznych.
  - Można stosować do znajdowania sieci neuronowych (**neuroevolution**)!
- Nie zawsze jest najlepszym rozwiązaniem. Dlaczego? Bo czasem wiemy coś więcej o funkcji  $f$  i możemy tą wiedzę wykorzystać (np. umiemy policzyć gradient i wtedy możemy stosować podejścia oparte o *gradient descent*).

# Automaty Komórkowe



# Demo: Game of Life

<https://playgameoflife.com/>

<https://golly.sourceforge.io/>






# Automaty komórkowe (cellular automata)

- Przestrzeń podzielona na **komórki** (niepodzielne, **dyskretne** elementy - kawałki przestrzeni). *Świat jest “w kratkę” - jak w Minecraft.*
- W danej chwili czasu komórka jest w określonym **stanie**. Zbiór stanów jest **skończony** (np. dwu elementowy).
- Stany podlegają ewolucji (zmianom) w czasie. Czasie jest **dyskretny**.
- Zmiana stanu odbywa się zgodnie z **deterministyczną** regułą lokalną.
- Stan komórki w chwili  $t + 1$  zależy od jej stanu w chwili  $t$  oraz od stanów jej **sąsiadów** w chwili  $t$ .








# Co zrobić aby zaprojektować automat komórkowy?

- Ustalić zbiór stanów. Ile elementów i jakie?
- Wybrać przestrzeń i podzielić ją na komórki - np. przestrzeń dwu-wymiarowa podzielona na “kratkę”.



# Co zrobić aby zaprojektować automat komórkowy?

- **Sąsiedztwo** - musimy wskazać co to znaczy, że komórka ma sąsiadków.




●● komórka "centralna"

●● komórka "sąsiednie" względem "centralnej"

# Co zrobić aby zaprojektować automat komórkowy?

- **Reguła lokalna** — funkcja która, dla danej **konfiguracji sąsiedztwa** (czyli uporządkowanych stanów w sąsiedztwie) wyliczy nowy stan.



$$f \begin{pmatrix} & x_u & \\ x_l & x_c & x_r \\ & x_d & \end{pmatrix}$$



$$f(x_u, x_l, x_c, x_r, x_d)$$

# Przykłady modeli CA

Załącznik: wykład #11 z przedmiotu CA


<https://github.com/houp/ca-class/blob/main/slides/lecture11.pdf>

# Co wynika z Automatów Komórkowych

- Proste modele złożonych procesów naturalnych
- Universal computation
- Emergent behavior - “całość jest większa niż suma części”
- Prosta definicja - skomplikowane własności



# ***UPGRADED !!***



<https://www.youtube.com/watch?v=7-97RhAZhXI>



# Dziękuję!

[Witold.Bolt@ug.edu.pl](mailto:Witold.Bolt@ug.edu.pl)



Współczesne  
Zastosowania  
Informatyki



JitTeam™

